

AUTOVALORES Y AUTOVECTORES

MÉTODO DE LA POTENCIA: CÓDIGO. FACTORIZACIÓN QR. CÓDIGO.

Manuel Carlevaro

Departamento de Ingeniería Mecánica

Grupo de Materiales Granulares - UTN FRLP

manuel.carlevaro@gmail.com

Cálculo Avanzado • 2023

 · X_gLaTeX · 

Método de las potencias: código

```
1  #!/usr/bin/env python3
2  import numpy as np
3
4  def iter_potencia(A, num_iteraciones):
5      n = A.shape[0]
6      # Inicializar un vector aleatorio de tamaño n
7      b = np.random.rand(n)
8      # Normalizar el vector
9      b = b / np.linalg.norm(b)
10
11     for _ in range(num_iteraciones):
12         # Multiplicar la matriz A por el vector b
13         Ab = np.dot(A, b)
14         # Calcular el autovalor dominante
15         autovalor = np.dot(b, Ab)
16         # Normalizar el vector resultante
17         b = Ab / np.linalg.norm(Ab)
18
19     # Devolver el autovalor dominante y el autovector
20     # correspondiente
21     return autovalor, b
```

```
23 # Ejemplo de uso
24 # Definir una matriz de ejemplo
25
26 A = np.array([[2, 0, 0],
27               [1, 1, 2],
28               [1, -1, 4]])
29
30 # Especificar el número de iteraciones
31 num_iteraciones = 100
32
33 # Aplicar el algoritmo de las potencias
34 autovalor, autovector = iter_potencia(A, num_iteraciones)
35
36 print(f"Autovalor dominante: {autovalor}")
37 print("Autovector correspondiente:")
```

```
$ ./potencias.py
Autovalor dominante: 3.0000000000000001
Autovector correspondiente:
[ 2.62486865e-19 -7.07106781e-01 -7.07106781e-01]
```

Teorema : .

Si \mathbf{A} es una matriz y $\lambda_1, \lambda_2, \dots, \lambda_k$ son autovalores distintos de \mathbf{A} con autovectores asociados $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$, entonces $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$ es un conjunto **linealmente independiente**.

Teorema : .

Si \mathbf{A} es una matriz y $\lambda_1, \lambda_2, \dots, \lambda_k$ son autovalores distintos de \mathbf{A} con autovectores asociados $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$, entonces $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$ es un conjunto **linealmente independiente**.

Definición : Conjunto ortogonal/ortonormal.

Un conjunto de vectores $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$ recibe el nombre de **ortogonal** si $\langle \mathbf{v}_i, \mathbf{v}_j \rangle = 0$ para todo $i \neq j$. Si, además, $\langle \mathbf{v}_i, \mathbf{v}_i \rangle = 1$ para toda $i = 1, 2, \dots, n$, el conjunto recibe el nombre de **ortonormal**.

Dado que $\langle \mathbf{x}, \mathbf{x} \rangle = \|\mathbf{x}\|_2^2, \forall \mathbf{x} \in \mathbb{R}^n$, el conjunto $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$ es ortonormal si y solo si:

$$\|\mathbf{v}_i\|_2 = 1 \text{ para todo } i = 1, 2, \dots, n$$

Teorema : .

Si \mathbf{A} es una matriz y $\lambda_1, \lambda_2, \dots, \lambda_k$ son autovalores distintos de \mathbf{A} con autovectores asociados $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$, entonces $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$ es un conjunto **linealmente independiente**.

Definición : Conjunto ortogonal/ortonormal.

Un conjunto de vectores $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$ recibe el nombre de **ortogonal** si $\langle \mathbf{v}_i, \mathbf{v}_j \rangle = 0$ para todo $i \neq j$. Si, además, $\langle \mathbf{v}_i, \mathbf{v}_i \rangle = 1$ para toda $i = 1, 2, \dots, n$, el conjunto recibe el nombre de **ortonormal**.

Dado que $\langle \mathbf{x}, \mathbf{x} \rangle = \|\mathbf{x}\|_2^2, \forall \mathbf{x} \in \mathbb{R}^n$, el conjunto $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$ es ortonormal si y solo si:

$$\|\mathbf{v}_i\|_2 = 1 \text{ para todo } i = 1, 2, \dots, n$$

Teorema : Proceso de Gram-Schmidt.

Sea $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k\}$ un conjunto de k vectores linealmente independientes en \mathbb{R}^n . Entonces, $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k\}$ definido mediante:

$$\mathbf{v}_1 = \mathbf{x}_1$$

$$\mathbf{v}_2 = \mathbf{x}_2 - \frac{\langle \mathbf{v}_1, \mathbf{x}_2 \rangle}{\langle \mathbf{v}_1, \mathbf{v}_1 \rangle} \mathbf{v}_1$$

$$\mathbf{v}_3 = \mathbf{x}_3 - \frac{\langle \mathbf{v}_1, \mathbf{x}_3 \rangle}{\langle \mathbf{v}_1, \mathbf{v}_1 \rangle} \mathbf{v}_1 - \frac{\langle \mathbf{v}_2, \mathbf{x}_3 \rangle}{\langle \mathbf{v}_2, \mathbf{v}_2 \rangle} \mathbf{v}_2$$

$$\vdots$$

$$\mathbf{v}_k = \mathbf{x}_k - \sum_{i=1}^{k-1} \frac{\langle \mathbf{v}_i, \mathbf{x}_k \rangle}{\langle \mathbf{v}_i, \mathbf{v}_i \rangle} \mathbf{v}_i$$

es un conjunto de k vectores ortogonales en \mathbb{R}^n .

Definición : Matriz ortogonal.

Se dice que una matriz Q es **ortogonal** si sus columnas $\{q_1, q_2, \dots, q_n\}$ forman un conjunto ortonormal en \mathbb{R}^n .

Definición : Matriz ortogonal.

Se dice que una matriz Q es **ortogonal** si sus columnas $\{q_1, q_2, \dots, q_n\}$ forman un conjunto ortonormal en \mathbb{R}^n .

Propiedades:

- ▶ Q es invertible con $Q^{-1} = Q^T$
- ▶ $\forall x, y \in \mathbb{R}^n, \langle Qx, Qy \rangle = \langle x, y \rangle$
- ▶ $\forall x \in \mathbb{R}^n, \|Qx\|_2 = \|x\|_2$
- ▶ Cualquier matriz invertible Q con $Q^{-1} = Q^T$ es ortogonal.

Definición : Matriz ortogonal.

Se dice que una matriz Q es **ortogonal** si sus columnas $\{q_1, q_2, \dots, q_n\}$ forman un conjunto ortonormal en \mathbb{R}^n .

Propiedades:

- ▶ Q es invertible con $Q^{-1} = Q^T$
- ▶ $\forall x, y \in \mathbb{R}^n, \langle Qx, Qy \rangle = \langle x, y \rangle$
- ▶ $\forall x \in \mathbb{R}^n, \|Qx\|_2 = \|x\|_2$
- ▶ Cualquier matriz invertible Q con $Q^{-1} = Q^T$ es ortogonal.

Definición : Matriz similar.

Dos matrices A y B son **similares** si existe una matriz no singular S con $A = S^{-1}BS$.

Definición : Matriz ortogonal.

Se dice que una matriz \mathbf{Q} es **ortogonal** si sus columnas $\{\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n\}$ forman un conjunto ortonormal en \mathbb{R}^n .

Propiedades:

- ▶ \mathbf{Q} es invertible con $\mathbf{Q}^{-1} = \mathbf{Q}^\top$
- ▶ $\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n, \langle \mathbf{Q}\mathbf{x}, \mathbf{Q}\mathbf{y} \rangle = \langle \mathbf{x}, \mathbf{y} \rangle$
- ▶ $\forall \mathbf{x} \in \mathbb{R}^n, \|\mathbf{Q}\mathbf{x}\|_2 = \|\mathbf{x}\|_2$
- ▶ Cualquier matriz invertible \mathbf{Q} con $\mathbf{Q}^{-1} = \mathbf{Q}^\top$ es ortogonal.

Definición : Matriz similar.

Dos matrices \mathbf{A} y \mathbf{B} son **similares** si existe una matriz no singular \mathbf{S} con $\mathbf{A} = \mathbf{S}^{-1}\mathbf{B}\mathbf{S}$.

Teorema : .

Si \mathbf{A} y \mathbf{B} son matrices similares con $\mathbf{A} = \mathbf{S}^{-1}\mathbf{B}\mathbf{S}$, y λ es un autovalor de \mathbf{A} con el autovector \mathbf{v} asociado, entonces λ es un autovalor de \mathbf{B} con autovector asociado $\mathbf{S}\mathbf{v}$.

Definición : Matriz ortogonal.

Se dice que una matriz Q es **ortogonal** si sus columnas $\{q_1, q_2, \dots, q_n\}$ forman un conjunto ortonormal en \mathbb{R}^n .

Propiedades:

- ▶ Q es invertible con $Q^{-1} = Q^T$
- ▶ $\forall x, y \in \mathbb{R}^n, \langle Qx, Qy \rangle = \langle x, y \rangle$
- ▶ $\forall x \in \mathbb{R}^n, \|Qx\|_2 = \|x\|_2$
- ▶ Cualquier matriz invertible Q con $Q^{-1} = Q^T$ es ortogonal.

Definición : Matriz similar.

Dos matrices A y B son **similares** si existe una matriz no singular S con $A = S^{-1}BS$.

Teorema : .

Si A y B son matrices similares con $A = S^{-1}BS$, y λ es un autovalor de A con el autovector v asociado, entonces λ es un autovalor de B con autovector asociado Sv .

Teorema : .

Una matriz $A \in \mathbb{R}^{n \times n}$ es similar a una matriz diagonal D si y sólo si A tiene n autovectores linealmente independientes. En este caso $D = S^{-1}AS$, donde las columnas de S son los autovectores y el i -ésimo elemento diagonal de D es el autovalor que corresponde a la i -ésima columna de S .

Teorema : Teorema de Schur.

Sea \mathbf{A} una matriz arbitraria. Existe una matriz no singular \mathbf{U} con la propiedad de que

$$\mathbf{T} = \mathbf{U}^{-1} \mathbf{A} \mathbf{U}$$

donde \mathbf{T} es una matriz triangular superior, cuyas entradas diagonales consisten en autovalores de \mathbf{A} .

Se cumple $\|\mathbf{U}\mathbf{x}\|_2 = \|\mathbf{x}\|_2, \forall \mathbf{x} \mapsto$ matrices unitarias.

Teorema : Teorema de Schur.

Sea \mathbf{A} una matriz arbitraria. Existe una matriz no singular \mathbf{U} con la propiedad de que

$$\mathbf{T} = \mathbf{U}^{-1} \mathbf{A} \mathbf{U}$$

donde \mathbf{T} es una matriz triangular superior, cuyas entradas diagonales consisten en autovalores de \mathbf{A} .

Se cumple $\|\mathbf{U}\mathbf{x}\|_2 = \|\mathbf{x}\|_2, \forall \mathbf{x} \mapsto$ **matrices unitarias**.

Factorización QR: $\mathbf{A} = \mathbf{Q}\mathbf{R}$, donde:

- ▶ \mathbf{Q} es una matriz ortogonal
- ▶ \mathbf{R} es una matriz triangular superior

Teorema : Teorema de Schur.

Sea \mathbf{A} una matriz arbitraria. Existe una matriz no singular \mathbf{U} con la propiedad de que

$$\mathbf{T} = \mathbf{U}^{-1} \mathbf{A} \mathbf{U}$$

donde \mathbf{T} es una matriz triangular superior, cuyas entradas diagonales consisten en autovalores de \mathbf{A} .

Se cumple $\|\mathbf{U}\mathbf{x}\|_2 = \|\mathbf{x}\|_2, \forall \mathbf{x} \mapsto$ matrices unitarias.

Factorización QR: $\mathbf{A} = \mathbf{Q}\mathbf{R}$, donde:

- ▶ \mathbf{Q} es una matriz ortogonal
- ▶ \mathbf{R} es una matriz triangular superior

Cálculo de la factorización:

- ▶ Ortogonalización de Gram-Schmidt
- ▶ Reflexiones de Householder

Ortogonalización de Gram-Schmidt:

$$\mathbf{A} = [\mathbf{a}_1 | \mathbf{a}_2 | \cdots | \mathbf{a}_n]$$

$$\mathbf{u}_1 = \mathbf{a}_1, \quad \mathbf{e}_1 = \frac{\mathbf{u}_1}{\|\mathbf{u}_1\|}$$

$$\mathbf{u}_2 = \mathbf{a}_2 - \langle \mathbf{e}_1, \mathbf{a}_2 \rangle \mathbf{e}_1, \quad \mathbf{e}_2 = \frac{\mathbf{u}_2}{\|\mathbf{u}_2\|}$$

$$\mathbf{u}_3 = \mathbf{a}_3 - \langle \mathbf{e}_1, \mathbf{a}_3 \rangle \mathbf{e}_1 - \langle \mathbf{e}_2, \mathbf{a}_3 \rangle \mathbf{e}_2, \quad \mathbf{e}_3 = \frac{\mathbf{u}_3}{\|\mathbf{u}_3\|}$$

\vdots

$$\mathbf{u}_k = \mathbf{a}_k - \sum_{j=1}^{k-1} \langle \mathbf{e}_j, \mathbf{a}_k \rangle \mathbf{e}_j, \quad \mathbf{e}_k = \frac{\mathbf{u}_k}{\|\mathbf{u}_k\|}$$

Teorema : Teorema de Schur.

Sea \mathbf{A} una matriz arbitraria. Existe una matriz no singular \mathbf{U} con la propiedad de que

$$\mathbf{T} = \mathbf{U}^{-1} \mathbf{A} \mathbf{U}$$

donde \mathbf{T} es una matriz triangular superior, cuyas entradas diagonales consisten en autovalores de \mathbf{A} .

Se cumple $\|\mathbf{U}\mathbf{x}\|_2 = \|\mathbf{x}\|_2, \forall \mathbf{x} \mapsto$ **matrices unitarias**.

Factorización QR: $\mathbf{A} = \mathbf{Q}\mathbf{R}$, donde:

- ▶ \mathbf{Q} es una matriz ortogonal
- ▶ \mathbf{R} es una matriz triangular superior

Cálculo de la factorización:

- ▶ Ortogonalización de Gram-Schmidt
- ▶ Reflexiones de Householder

Ortogonalización de Gram-Schmidt:

$$\mathbf{A} = [\mathbf{a}_1 | \mathbf{a}_2 | \cdots | \mathbf{a}_n]$$

$$\mathbf{u}_1 = \mathbf{a}_1, \quad \mathbf{e}_1 = \frac{\mathbf{u}_1}{\|\mathbf{u}_1\|}$$

$$\mathbf{u}_2 = \mathbf{a}_2 - \langle \mathbf{e}_1, \mathbf{a}_2 \rangle \mathbf{e}_1, \quad \mathbf{e}_2 = \frac{\mathbf{u}_2}{\|\mathbf{u}_2\|}$$

$$\mathbf{u}_3 = \mathbf{a}_3 - \langle \mathbf{e}_1, \mathbf{a}_3 \rangle \mathbf{e}_1 - \langle \mathbf{e}_2, \mathbf{a}_3 \rangle \mathbf{e}_2, \quad \mathbf{e}_3 = \frac{\mathbf{u}_3}{\|\mathbf{u}_3\|}$$

\vdots

$$\mathbf{u}_k = \mathbf{a}_k - \sum_{j=1}^{k-1} \langle \mathbf{e}_j, \mathbf{a}_k \rangle \mathbf{e}_j, \quad \mathbf{e}_k = \frac{\mathbf{u}_k}{\|\mathbf{u}_k\|}$$

Ahora podemos expresar los \mathbf{a}_i en la nueva base:

$$\mathbf{a}_1 = \langle \mathbf{e}_1, \mathbf{a}_1 \rangle \mathbf{e}_1$$

$$\mathbf{a}_1 = \langle \mathbf{e}_1, \mathbf{a}_2 \rangle \mathbf{e}_1 + \langle \mathbf{e}_2, \mathbf{a}_2 \rangle \mathbf{e}_2$$

$$\mathbf{a}_3 = \langle \mathbf{e}_1, \mathbf{a}_3 \rangle \mathbf{e}_1 + \langle \mathbf{e}_2, \mathbf{a}_3 \rangle \mathbf{e}_2 + \langle \mathbf{e}_3, \mathbf{a}_3 \rangle \mathbf{e}_3$$

\dots

$$\mathbf{a}_k = \sum_{j=1}^k \langle \mathbf{e}_j, \mathbf{a}_k \rangle \mathbf{e}_j$$

Resulta $\mathbf{A} = \mathbf{QR}$, con $\mathbf{Q} = [e_1|e_2|\cdots|e_n]$, y

$$\mathbf{R} = \begin{bmatrix} \langle e_1 a_1 \rangle & \langle e_1 a_2 \rangle & \langle e_1 a_3 \rangle & \cdots & \langle e_1 a_n \rangle \\ 0 & \langle e_2 a_2 \rangle & \langle e_2 a_3 \rangle & \cdots & \langle e_2 a_n \rangle \\ 0 & 0 & \langle e_3 a_3 \rangle & \cdots & \langle e_3 a_n \rangle \\ \vdots & \vdots & \vdots & \ddots & \cdots \\ 0 & 0 & 0 & \cdots & \langle e_n, a_n \rangle \end{bmatrix}$$

Resulta $A = QR$, con $Q = [e_1|e_2|\dots|e_n]$, y

$$R = \begin{bmatrix} \langle e_1 a_1 \rangle & \langle e_1 a_2 \rangle & \langle e_1 a_3 \rangle & \cdots & \langle e_1 a_n \rangle \\ 0 & \langle e_2 a_2 \rangle & \langle e_2 a_3 \rangle & \cdots & \langle e_2 a_n \rangle \\ 0 & 0 & \langle e_3 a_3 \rangle & \cdots & \langle e_3 a_n \rangle \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & \langle e_n a_n \rangle \end{bmatrix}$$

Código Python:

```
1 #!/usr/bin/env python3
2
3 import numpy as np
4
5 def gram_schmidt_qr(A):
6     m, n = A.shape
7     Q = np.zeros((m, n))
8     R = np.zeros((n, n))
```

```
10     for j in range(n):
11         v = A[:, j]
12         for i in range(j):
13             R[i, j] = np.dot(Q[:, i], A[:, j])
14             v = v - R[i, j] * Q[:, i]
15         R[j, j] = np.linalg.norm(v)
16         Q[:, j] = v / R[j, j]
17
18     return Q, R
19
20 # Ejemplo de uso
21 # Definir una matriz de ejemplo
22 A = np.array([[1, 4, 3],
23               [2, 5, 1],
24               [3, 6, 2]])
25
26 # Aplicar la factorización QR usando el método
27 # de Gram-Schmidt
28 Q, R = gram_schmidt_qr(A)
29
30 print("Matriz Q:")
31 print(Q)
32 print("Matriz R:")
33 print(R)
```


Método QR para el cálculo de autovalores:

Algoritmo recursivo que computa $\{\mathbf{A}_k\}_{k=0}^{\infty}$ con los siguientes pasos:

1. $\mathbf{A}_0 = \mathbf{A}$
2. Para $k = 0, 1, 2, \dots$, dado \mathbf{A}_k :
 - 2.1 Calcular $\mathbf{Q}_{k+1}\mathbf{R}_{k+1} = \mathbf{A}_k$
 - 2.2 Definir $\mathbf{A}_{k+1} = \mathbf{Q}_{k+1}\mathbf{R}_{k+1}$

Método QR para el cálculo de autovalores:

Algoritmo recursivo que computa $\{A_k\}_{k=0}^{\infty}$ con los siguientes pasos:

1. $A_0 = A$
2. Para $k = 0, 1, 2, \dots$, dado A_k :
 - 2.1 Calcular $Q_{k+1}R_{k+1} = A_k$
 - 2.2 Definir $A_{k+1} = Q_{k+1}R_{k+1}$

Teorema : Convergencia.

Si los autovalores de una matriz A verifican que

$$|\lambda_1| > |\lambda_2| > \dots > |\lambda_n| > 0$$

entonces la sucesión de matrices equivalentes contruidas con el algoritmo QR converge a una matriz triangular superior.

Código Python:

```
1 #!/usr/bin/env python3
2 import numpy as np
3
4 def algoritmo_qr(A, num_iter):
5     n = A.shape[0]
6     autovalores = np.zeros(n, dtype=np.complex128)
7     for _ in range(num_iter):
8         Q, R = np.linalg.qr(A)
9         A = np.dot(R, Q)
10    for i in range(n):
11        autovalores[i] = A[i, i]
12    return autovalores
13
14 A = np.array([[1, 2, 3],
15               [4, 5, 6],
16               [7, 8, 9]])
17
18 num_iter = 100
19 autovalores = algoritmo_qr(A, num_iter)
20 print("Autovalores:")
21 print(autovalores)
```

- ▶ R.L. Burden, D.J. Faires y A.M. Burden. *Análisis numérico*. 10.^a ed. Mexico: Cengage Learning, 2017. Capítulo 9.
- ▶ Carlos Moreno González. *Introducción al cálculo numérico*. Madrid, España: Universidad Nacional de Educación a Distancia, 2014. Capítulo 3.
- ▶ B. Bradie. *A Friendly Introduction to Numerical Analysis*. New Jersey, United States: Pearson Education Inc., 2006. Capítulo 4.
- ▶ A.J. Salgado y S.M. Wise. *Classical Numerical Analysis*. Cambridge, United Kingdom: Cambridge University Press, 2023. doi: [10.1017/9781108942607](https://doi.org/10.1017/9781108942607). Capítulo 8.
- ▶ A. Quarteroni, R. Sacco y F. Saleri. *Numerical Mathematics*. New York, United States: Springer-Verlag, 2000. Capítulo 5.