

AUTOVALORES Y AUTOVECTORES

DEFINICIONES. INTERPRETACIÓN GEOMÉTRICA. CÍRCULOS DE GERSCHGORIN. MÉTODO DE LAS POTENCIAS.

Manuel Carlevaro

Departamento de Ingeniería Mecánica

Grupo de Materiales Granulares - UTN FRLP

manuel.carlevaro@gmail.com

Cálculo Avanzado • 2023

 · X_YLaTeX · 

Definición : Autovalor y autovector.

Sea $\mathbf{A} \in K^{n \times n}$ y $\mathbf{v} \in K^n$. \mathbf{v} es un **autovector** de \mathbf{A} si

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

donde λ es un escalar en K , denominado **autovalor** asociado con \mathbf{v} .

Definición : Autovalor y autovector.

Sea $\mathbf{A} \in K^{n \times n}$ y $\mathbf{v} \in K^n$. \mathbf{v} es un **autovector** de \mathbf{A} si

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

donde λ es un escalar en K , denominado **autovalor** asociado con \mathbf{v} .

En forma equivalente:

$$(\mathbf{A} - \lambda\mathbf{I})\mathbf{v} = \mathbf{0} \quad (1)$$

Este sistema tiene solución $\mathbf{v} \neq \mathbf{0}$ si y solo si:

$$\det(\mathbf{A} - \lambda\mathbf{I}) = 0$$

denominado **polinomio característico**, $p_A(\lambda)$, y por el teorema fundamental del álgebra: $\mapsto n$ raíces.

Definición : Autovalor y autovector.

Sea $\mathbf{A} \in K^{n \times n}$ y $\mathbf{v} \in K^n$. \mathbf{v} es un **autovector** de \mathbf{A} si

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

donde λ es un escalar en K , denominado **autovalor** asociado con \mathbf{v} .

En forma equivalente:

$$(\mathbf{A} - \lambda\mathbf{I})\mathbf{v} = \mathbf{0} \quad (1)$$

Este sistema tiene solución $\mathbf{v} \neq \mathbf{0}$ si y solo si:

$$\det(\mathbf{A} - \lambda\mathbf{I}) = 0$$

denominado **polinomio característico**, $p_A(\lambda)$, y por el teorema fundamental del álgebra: $\mapsto n$ raíces.

Ejemplo:

$$\mathbf{A} = \begin{bmatrix} 3 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 3 \end{bmatrix}$$

$$\begin{aligned} p_A(\lambda) = \det(\mathbf{A} - \lambda\mathbf{I}) &= \begin{vmatrix} 3 - \lambda & -1 & 0 \\ -1 & 2 - \lambda & -1 \\ 0 & -1 & 3 - \lambda \end{vmatrix} \\ &= -\lambda^3 + 8\lambda^2 - 19\lambda + 12 = 0 \end{aligned}$$

Solución: $\lambda_1 = 1, \lambda_2 = 3, \lambda_3 = 4$. Reemplazando cada autovalor en (1):

$$\mathbf{v}_1 = a \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}, \mathbf{v}_2 = b \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}, \mathbf{v}_3 = c \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix}$$

Definición : Autovalor y autovector.

Sea $\mathbf{A} \in K^{n \times n}$ y $\mathbf{v} \in K^n$. \mathbf{v} es un **autovector** de \mathbf{A} si

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$$

donde λ es un escalar en K , denominado **autovalor** asociado con \mathbf{v} .

En forma equivalente:

$$(\mathbf{A} - \lambda\mathbf{I})\mathbf{v} = \mathbf{0} \quad (1)$$

Este sistema tiene solución $\mathbf{v} \neq \mathbf{0}$ si y solo si:

$$\det(\mathbf{A} - \lambda\mathbf{I}) = 0$$

denominado **polinomio característico**, $p_A(\lambda)$, y por el teorema fundamental del álgebra: $\mapsto n$ raíces.

Ejemplo:

$$\mathbf{A} = \begin{bmatrix} 3 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 3 \end{bmatrix}$$

$$\begin{aligned} p_A(\lambda) = \det(\mathbf{A} - \lambda\mathbf{I}) &= \begin{vmatrix} 3-\lambda & -1 & 0 \\ -1 & 2-\lambda & -1 \\ 0 & -1 & 3-\lambda \end{vmatrix} \\ &= -\lambda^3 + 8\lambda^2 - 19\lambda + 12 = 0 \end{aligned}$$

Solución: $\lambda_1 = 1, \lambda_2 = 3, \lambda_3 = 4$. Reemplazando cada autovalor en (1):


$$\mathbf{v}_1 = a \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}, \mathbf{v}_2 = b \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}, \mathbf{v}_3 = c \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix}$$

Definiciones:

Espectro de \mathbf{A} : $\sigma(\mathbf{A}) = \{\lambda_1, \lambda_2, \dots, \lambda_n\}$


Radio espectral de \mathbf{A} : $\rho(\mathbf{A}) = \max_{\lambda \in \sigma(\mathbf{A})} |\lambda|$

Intepretación gráfica



$$\begin{aligned} p_A(\lambda) &= \det(\mathbf{A} - \lambda \mathbf{I}) = \begin{vmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{vmatrix} \\ &= (2 - \lambda)^2 - 1 = \lambda^2 - 4\lambda + 3 = (\lambda - 3)(\lambda - 1) = 0 \end{aligned}$$

Intepretación gráfica




$$\begin{aligned} p_A(\lambda) &= \det(\mathbf{A} - \lambda \mathbf{I}) = \begin{vmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{vmatrix} \\ &= (2 - \lambda)^2 - 1 = \lambda^2 - 4\lambda + 3 = (\lambda - 3)(\lambda - 1) = 0 \end{aligned}$$

Con $\lambda_1 = 3$:

$$\begin{cases} (2 - 3)x + y = 0 \\ x + (2 - 3)y = 0 \end{cases} \implies \mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Interpretación gráfica



$$\begin{aligned} p_A(\lambda) &= \det(\mathbf{A} - \lambda \mathbf{I}) = \begin{vmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{vmatrix} \\ &= (2 - \lambda)^2 - 1 = \lambda^2 - 4\lambda + 3 = (\lambda - 3)(\lambda - 1) = 0 \end{aligned}$$

Con $\lambda_1 = 3$:

$$\begin{cases} (2 - 3)x + y = 0 \\ x + (2 - 3)y = 0 \end{cases} \implies \mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Con $\lambda_2 = 1$:

$$\begin{cases} (2 - 1)x + y = 0 \\ x + (2 - 1)y = 0 \end{cases} \implies \mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

Nota: si consideramos la norma vectorial $l_2 : \|\cdot\|$:

$$\|\mathbf{A}\|_2 = \rho(\mathbf{A}^\dagger \mathbf{A})^{1/2}$$

Si \mathbf{A} es simétrica, $\|\mathbf{A}\|_2 = \rho(\mathbf{A})$.

Métodos:

- ▶ Analítico: $n < 5$.
 - ▶ Parciales: computan solo autovalores **extremos** (módulo máximo o mínimo). Método de las potencias.
 - ▶ Globales: aproximan a todo el **espectro** de \mathbf{A} , $\sigma(\mathbf{A})$. Método QR .
-

Métodos:

- ▶ Analítico: $n < 5$.
- ▶ Parciales: computan solo autovalores **extremos** (módulo máximo o mínimo). Método de las potencias.
- ▶ Globales: aproximan a todo el **espectro** de \mathbf{A} , $\sigma(\mathbf{A})$. Método QR .

Teorema : Círculo de Gerschgorin.

$\mathbf{A} \in K^{n \times n}$, $r_i = \sum_{j \neq i}^n |a_{ij}|$ para cada $i = 1, 2, \dots, n$. Sea

$$C_i = \{z \in \mathbb{C} : |z - a_{ii}| \leq r_i\}$$

1. Si λ es un autovalor, está en uno de los C_i .
2. Si k círculos C_i forman una región conectada $R \in \mathbb{C}$, disjunta de los restantes $n - k$ círculos, entonces R contiene exactamente k autovalores.

Métodos:

- ▶ Analítico: $n < 5$.
- ▶ Parciales: computan solo autovalores **extremos** (módulo máximo o mínimo). Método de las potencias.
- ▶ Globales: aproximan a todo el **espectro** de \mathbf{A} , $\sigma(\mathbf{A})$. Método QR .

Teorema : Círculo de Gerschgorin.

$\mathbf{A} \in K^{n \times n}$, $r_i = \sum_{j \neq i}^n |a_{ij}|$ para cada $i = 1, 2, \dots, n$. Sea


$$C_i = \{z \in \mathbb{C} : |z - a_{ii}| \leq r_i\}$$

1. Si λ es un autovalor, está en uno de los C_i .
2. Si k círculos C_i forman una región conectada $R \in \mathbb{C}$, disjunta de los restantes $n - k$ círculos, entonces R contiene exactamente k autovalores.

Ejemplo:

$$\begin{bmatrix} 1 & -1 & 0 \\ 1 & 5 & 1 \\ -2 & -1 & 9 \end{bmatrix}$$

$$r_1 = |-1| + |0| = 1, r_2 = |1| + |1| = 2, r_3 = |-2| + |-1| = 3.$$
$$\lambda_1 = 1.33192769, \lambda_2 = 8.81113862, \lambda_3 = 4.85693369.$$



Método de las potencias:

$\mathbf{A} \in \mathbb{R}^{n \times n}$, con elementos de $\sigma(\mathbf{A})$ que satisfacen: $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$. λ_1 : **autovalor dominante**. $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$ forman una **base** en \mathbb{R}^n (linealmente independientes).

$$\mathbf{x} = \sum_{j=1}^n \beta_j \mathbf{v}_j$$

Multiplicando ambos miembros por $\mathbf{A}, \mathbf{A}^2, \dots, \mathbf{A}^k, \dots$:

$$\mathbf{A}\mathbf{x} = \sum_{j=1}^n \beta_j \mathbf{A}\mathbf{v}_j = \sum_{j=1}^n \beta_j \lambda_j \mathbf{v}_j$$

$$\mathbf{A}^2\mathbf{x} = \sum_{j=1}^n \beta_j \lambda_j \mathbf{A}\mathbf{v}_j = \sum_{j=1}^n \beta_j \lambda_j^2 \mathbf{v}_j$$

\vdots

$$\mathbf{A}^k\mathbf{x} = \sum_{j=1}^n \beta_j \lambda_j^k \mathbf{v}_j$$

Factorizando λ_1 en la última ecuación:

$$\mathbf{A}^k\mathbf{x} = \lambda_1^k \sum_{j=1}^n \beta_j \left(\frac{\lambda_j}{\lambda_1}\right)^k \mathbf{v}_j$$

Dado que $\forall j, |\lambda_1| > |\lambda_j|$; $\lim_{k \rightarrow \infty} (\lambda_j/\lambda_1)^k = 0$, y

$$\lim_{k \rightarrow \infty} \mathbf{A}^k\mathbf{x} = \lim_{k \rightarrow \infty} \lambda_1^k \beta_1 \mathbf{v}_1 \quad (2)$$

Si $|\lambda_1| < 1$, (2) $\mapsto \mathbf{0}$, si $|\lambda_1| > 1$, (2) diverge ($\beta_1 \neq 0$). Elegimos $\mathbf{x} = \mathbf{x}^{(0)}$ con $\|\cdot\|_\infty$: $x_{p_0}^{(0)}$ con

$$x_{p_0}^{(0)} = 1 = \|\mathbf{x}^{(0)}\|_\infty$$

Hacemos $\mathbf{y}_{(1)} = \mathbf{A}\mathbf{x}^{(0)}$ y definimos $\mu^{(1)} = y_{p_0}^{(1)}$:

$$\begin{aligned} \mu^{(1)} &= y_{p_0}^{(1)} = \frac{y_{p_1}^{(1)}}{x_{p_0}^{(0)}} = \frac{\beta_1 \lambda_1 v_{p_0}^{(1)} + \sum_{j=2}^n \beta_j \lambda_j v_{p_0}^{(j)}}{\beta_1 v_{p_0}^{(1)} + \sum_{j=2}^n \beta_j v_{p_0}^{(j)}} \\ &= \lambda_1 \left[\frac{\beta_1 v_{p_0}^{(1)} + \sum_{j=2}^n \beta_j (\lambda_j/\lambda_1) v_{p_0}^{(j)}}{\beta_1 v_{p_0}^{(1)} + \sum_{j=2}^n \beta_j v_{p_0}^{(j)}} \right] \end{aligned}$$

Sea p_1 el menor entero tal que $|y_{p_1}^{(1)}| = \|\mathbf{y}^{(1)}\|_\infty$:

$$\mathbf{x}^{(1)} = \frac{\mathbf{y}^{(1)}}{y_{p_1}^{(1)}} = \frac{1}{y_{p_1}^{(1)}} \mathbf{A} \mathbf{x}^{(0)}$$

Entonces: $x_{p_1}^{(1)} = 1 = \|\mathbf{x}^{(1)}\|_\infty$. Ahora

$$\mathbf{y}^{(2)} = \mathbf{A} \mathbf{x}^{(1)} = \frac{1}{y_{p_1}^{(1)}} \mathbf{A}^2 \mathbf{x}^{(0)}$$

y

$$\begin{aligned} \mu^{(2)} = y_{p_1}^{(2)} &= \frac{y_{p_1}^{(2)}}{x_{p_1}^{(1)}} = \frac{\left[\beta_1 \lambda_1^2 v_{p_1}^{(1)} + \sum_{j=2}^n \beta_j \lambda_j^2 v_{p_1}^{(j)} \right] / y_{p_1}^{(1)}}{\left[\beta_1 \lambda_1 v_{p_1}^{(1)} + \sum_{j=2}^n \beta_j \lambda_j v_{p_1}^{(j)} \right] / y_{p_1}^{(1)}} \\ &= \lambda_1 \left[\frac{\beta_1 v_{p_1}^{(1)} + \sum_{j=2}^n \beta_j (\lambda_j / \lambda_1)^2 v_{p_1}^{(j)}}{\beta_1 v_{p_1}^{(1)} + \sum_{j=2}^n \beta_j (\lambda_j / \lambda_1) v_{p_1}^{(j)}} \right] \end{aligned}$$

Sea p_2 el menor entero tal que $|y_{p_2}^{(2)}| = \|\mathbf{y}^{(2)}\|_\infty$:

$$\mathbf{x}^{(2)} = \frac{\mathbf{y}^{(2)}}{y_{p_2}^{(2)}} = \frac{1}{y_{p_2}^{(2)}} \mathbf{A} \mathbf{x}^{(1)} = \frac{1}{y_{p_2}^{(2)} y_{p_1}^{(1)}} \mathbf{A}^2 \mathbf{x}^{(0)}$$

\mapsto secuencias $\{\mathbf{x}^{(m)}\}_{m=0}^\infty$, $\{\mathbf{y}^{(m)}\}_{m=0}^\infty$, $\{\mu^{(m)}\}_{m=0}^\infty$, inductivamente:

$$\mathbf{y}^{(m)} = \mathbf{A} \mathbf{x}^{(m-1)}$$

$$\begin{aligned} \mu^{(m)} &= y_{p_{m-1}}^{(m)} \\ &= \lambda_1 \left[\frac{\beta_1 v_{p_{m-1}}^{(1)} + \sum_{j=2}^n (\lambda_j / \lambda_1)^m \beta_j v_{p_{m-1}}^{(j)}}{\beta_1 v_{p_{m-1}}^{(1)} + \sum_{j=2}^n (\lambda_j / \lambda_1)^{m-1} \beta_j v_{p_{m-1}}^{(j)}} \right] \end{aligned}$$

y

$$\mathbf{x}^{(m)} = \frac{\mathbf{y}^{(m)}}{y_{p_m}^{(m)}} = \frac{\mathbf{A}^m \mathbf{x}^{(0)}}{\prod_{k=1}^m y_{p_k}^{(k)}}$$

donde para cada paso, p_m es el menor entero para el cual $|y_{p_m}^{(m)}| = \|\mathbf{y}^{(m)}\|_\infty$.

Dado que $|\lambda_j / \lambda_1| < 1, j = 2, \dots, n$,

$\lim_{m \rightarrow \infty} \mu^{(m)} = \lambda_1$, eligiendo $\mathbf{x}^{(0)}$ tal que $\beta_1 \neq 0$.

Además, la secuencia $\{\mathbf{x}^{(m)}\}_{m=0}^\infty$ converge al autovalor asociado con λ_1 con norma l_∞ igual a 1.

Ejemplo:

$$\mathbf{A} = \begin{bmatrix} -2 & -3 \\ 6 & 7 \end{bmatrix}, \mathbf{v}_1 = \begin{bmatrix} 1 \\ -2 \end{bmatrix}, \mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

Con $\sigma(\mathbf{A}) = \{4, 1\}$. Tomemos $\mathbf{x}^{(0)} = [1, 1]^\top$:

$$\mathbf{x}^{(1)} = \mathbf{A}\mathbf{x}^{(0)} = \begin{bmatrix} -5 \\ 13 \end{bmatrix}, \mathbf{x}^{(2)} = \mathbf{A}\mathbf{x}^{(1)} = \begin{bmatrix} -29 \\ 61 \end{bmatrix}$$

$$\mathbf{x}^{(3)} = \mathbf{A}\mathbf{x}^{(2)} = \begin{bmatrix} -125 \\ 253 \end{bmatrix}, \mathbf{x}^{(4)} = \mathbf{A}\mathbf{x}^{(3)} = \begin{bmatrix} -509 \\ 1021 \end{bmatrix}$$

$$\mathbf{x}^{(5)} = \mathbf{A}\mathbf{x}^{(4)} = \begin{bmatrix} -2045 \\ 4093 \end{bmatrix}, \mathbf{x}^{(6)} = \mathbf{A}\mathbf{x}^{(5)} = \begin{bmatrix} -8189 \\ 16381 \end{bmatrix}$$

Aproximaciones al autovalor dominante λ_1 :

$$\lambda_1^{(1)} = \frac{61}{13} = 4.6923, \quad \lambda_1^{(2)} = \frac{253}{61} = 4.14654$$

$$\lambda_1^{(3)} = \frac{1021}{253} = 4.03557, \quad \lambda_1^{(4)} = \frac{4093}{1021} = 4.00881$$

$$\lambda_1^{(5)} = \frac{16381}{4093} = 4.00200$$

Un autovector aproximado para

$\lambda_1^{(5)} = 16381/4093 = 4.00200$ es

$$\mathbf{x}^{(6)} = \begin{bmatrix} -8189 \\ 16381 \end{bmatrix} \rightarrow \begin{bmatrix} -0.49908 \\ 1 \end{bmatrix} \approx \mathbf{v}_1$$

Ejemplo:

$$\mathbf{A} = \begin{bmatrix} -2 & -3 \\ 6 & 7 \end{bmatrix}, \mathbf{v}_1 = \begin{bmatrix} 1 \\ -2 \end{bmatrix}, \mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

Con $\sigma(\mathbf{A}) = \{4, 1\}$. Tomemos $\mathbf{x}^{(0)} = [1, 1]^\top$:

$$\mathbf{x}^{(1)} = \mathbf{A}\mathbf{x}^{(0)} = \begin{bmatrix} -5 \\ 13 \end{bmatrix}, \mathbf{x}^{(2)} = \mathbf{A}\mathbf{x}^{(1)} = \begin{bmatrix} -29 \\ 61 \end{bmatrix}$$

$$\mathbf{x}^{(3)} = \mathbf{A}\mathbf{x}^{(2)} = \begin{bmatrix} -125 \\ 253 \end{bmatrix}, \mathbf{x}^{(4)} = \mathbf{A}\mathbf{x}^{(3)} = \begin{bmatrix} -509 \\ 1021 \end{bmatrix}$$

$$\mathbf{x}^{(5)} = \mathbf{A}\mathbf{x}^{(4)} = \begin{bmatrix} -2045 \\ 4093 \end{bmatrix}, \mathbf{x}^{(6)} = \mathbf{A}\mathbf{x}^{(5)} = \begin{bmatrix} -8189 \\ 16381 \end{bmatrix}$$

Aproximaciones al autovalor dominante λ_1 :

$$\lambda_1^{(1)} = \frac{61}{13} = 4.6923, \quad \lambda_1^{(2)} = \frac{253}{61} = 4.14654$$

$$\lambda_1^{(3)} = \frac{1021}{253} = 4.03557, \quad \lambda_1^{(4)} = \frac{4093}{1021} = 4.00881$$

$$\lambda_1^{(5)} = \frac{16381}{4093} = 4.00200$$

Un autovector aproximado para

$$\lambda_1^{(5)} = 16381/4093 = 4.00200 \text{ es}$$

$$\mathbf{x}^{(6)} = \begin{bmatrix} -8189 \\ 16381 \end{bmatrix} \rightarrow \begin{bmatrix} -0.49908 \\ 1 \end{bmatrix} \approx \mathbf{v}_1$$

Desventajas:

- ▶ No se sabe al inicio si \mathbf{A} tiene un autovalor dominante.
- ▶ No se conoce cómo debe elegirse $\mathbf{x}^{(9)}$ para que tenga una contribución no nula del autovector asociado al autovalor dominante, si existe.

- ▶ R.L. Burden, D.J. Faires y A.M. Burden. *Análisis numérico*. 10.^a ed. Mexico: Cengage Learning, 2017. Capítulo 9.
- ▶ Carlos Moreno González. *Introducción al cálculo numérico*. Madrid, España: Universidad Nacional de Educación a Distancia, 2014. Capítulo 3.
- ▶ B. Bradie. *A Friendly Introduction to Numerical Analysis*. New Jersey, United States: Pearson Education Inc., 2006. Capítulo 4.
- ▶ A.J. Salgado y S.M. Wise. *Classical Numerical Analysis*. Cambridge, United Kingdom: Cambridge University Press, 2023. doi: [10.1017/9781108942607](https://doi.org/10.1017/9781108942607). Capítulo 8.
- ▶ A. Quarteroni, R. Sacco y F. Saleri. *Numerical Mathematics*. New York, United States: Springer-Verlag, 2000. Capítulo 5.